Исследовательский отчет

Тема проекта

Проверка гипотезы: локальные модели на каждый ряд проигрывают глобальным моделям, если рядов много и они похожи по структуре.

Распределение ролей

Проект выполнен индивидуально. Все этапы работы, включая подготовку репозитория, реализацию кода, загрузку и обработку данных, запуск экспериментов, анализ результатов и подготовку отчета, выполнены одним человеком.

Постановка задачи

Цель проекта состояла в том, чтобы проверить, помогает ли объединение нескольких похожих временных рядов улучшить качество прогноза по сравнению с локальным обучением на каждом ряде отдельно. Для этого было решено сравнить одну и ту же основную модель `CatBoost` в трех режимах:

? локальная модель на каждый временной ряд;
? глобальная модель внутри кластеров похожих рядов;
? единая глобальная модель на всей выборке.

Чтобы сравнение было корректным, дополнительно использовались обязательные бейзлайны `Naive`, `SeasonalNaive`, `AutoETS` и `AutoTheta`.

Данные

В качестве данных использовался датасет `M4 Monthly` из `datasetsforecast`. Выбор именно этой группы объясняется тремя причинами:

? в ней много месячных рядов, что делает задачу сравнения локальных и глобальных моделей содержательной;
? для месячных рядов естественно использовать сезонность `12`, поэтому сезонный бейзлайн применим без натяжек;
? объем данных остается реалистичным для аккуратного эксперимента в рамках одной недели.

В итоговом запуске использовалась воспроизводимая подвыборка из `120` временных рядов. Горизонт прогноза составил `18`, сезонность была зафиксирована равной `12`. Для всех рядов последние `18` наблюдений были отложены в тест, а

все предыдущие значения использовались для обучения.

Методология эксперимента

Сначала на обучающей части каждого ряда рассчитывались простые статистические признаки: длина ряда, среднее, стандартное отклонение, коэффициент вариации, наклон линейного тренда, автокорреляция первого лага, сезонная автокорреляция, а также сила тренда и сила сезонности на основе `STL`-разложения. Эти признаки использовались для кластеризации рядов методом `KMeans`.

Число кластеров выбиралось по метрике `silhouette score` среди значений от `2` до `6`. Лучшее качество было достигнуто при `k = 5`, где `silhouette score` составил `0.310`. Итоговое распределение рядов по кластерам оказалось неравномерным: `64`, `4`, `23`, `25` и `4` ряда соответственно.

Для основной модели `CatBoost` использовались лаговые признаки `1, 2, 3, 6, 12, 18, 24`, скользящие средние и стандартные отклонения по окнам `3, 6, 12`, разность по первому лагу, сезонная разность и простые сезонные признаки в виде синуса и косинуса. Перед обучением применялось масштабирование по среднему абсолютному уровню каждого ряда, а после прогноза предсказания возвращались в исходную шкалу. Все метрики считались только после этого обратного преобразования.

Качество оценивалось по трем метрикам:

? `sMAPE` как основная метрика сравнения рядов разного масштаба;
? `MASE` как масштабно-нормированная ошибка;
? `RMSE` как чувствительная к крупным ошибкам дополнительная метрика.

Дополнительно результаты анализировались не только в среднем по всему горизонту, но и по каждому шагу прогноза отдельно.

Описание моделей

В отчете сравнивались следующие модели:

? `Naive`;
? `SeasonalNaive`;
? `AutoETS`;
? `AutoTheta`;
? `CatBoostLocal`;
? `CatBoostClusterGlobal`;
? `CatBoostGlobal`.

Бейзлайны `AutoETS` и `AutoTheta` запускались через библиотеку `statsforecast`. Основное сравнение строилось вокруг `CatBoost`, чтобы отследить влияние именно режима обучения, а не смены класса модели.

Результаты

Итоговые метрики на подвыборке из `120` рядов представлены в таблице ниже.

Модель	sMAPE	MASE	RMSE
AutoTheta	14.638	0.924	1106.265
AutoETS	15.186	0.920	1142.728
CatBoostGlobal	16.031	1.158	1304.643
CatBoostLocal	16.593	1.125	1287.164
Naive	16.930	1.086	1358.838
CatBoostClusterGlobal	16.958	1.142	1379.772
SeasonalNaive	18.254	1.190	1315.108

Среди всех моделей лучшей по `sMAPE` оказалась `AutoTheta`. Второе место заняла `AutoETS`. Это означает, что на выбранной постановке классические автоматические локальные модели оказались сильнее, чем все варианты `CatBoost`.

Если сравнивать только три варианта `CatBoost`, то лучшей оказалась единая глобальная модель `CatBoostGlobal` со `sMAPE = 16.031`. Локальный вариант получил `16.593`, а кластерный глобальный вариант `16.958`. Таким образом, внутри класса `CatBoost` глобальное обучение действительно оказалось лучше локального, но разница была умеренной, а кластеризация не принесла прироста.

Отдельный анализ по шагам горизонта показал, что внутри семейства `CatBoost` глобальная модель была лучшей на `13` из `18` шагов горизонта, локальная модель выигрывала на `5` шагах, а кластерный глобальный вариант не оказался лучшим ни на одном шаге. Если же смотреть на все модели сразу, то:

? `AutoTheta` была лучшей на `13` шагах горизонта;
? `AutoETS` была лучшей на `4` шагах;
? `CatBoostGlobal` оказался лучшим только на `1` шаге.

Это означает, что преимущество классических моделей было не случайным и не ограничивалось только усредненной метрикой на всем горизонте.

Ниже приведены автоматически сохраненные графики, полученные в эксперименте.

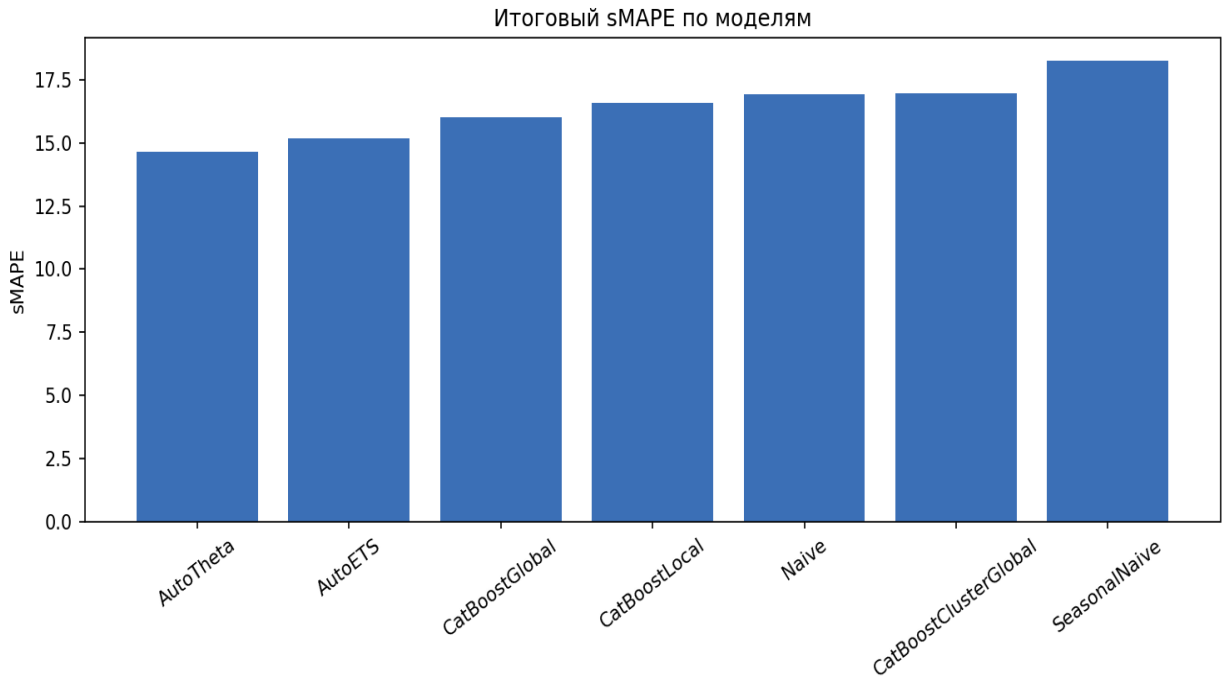
Итоговый sMAPE по моделям
sMAPE
0.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
AutoTheta
AutoETS
CatBoostGlobal
CatBoostLocal
Naive
CatBoostClusterGlobal
SeasonalNaive

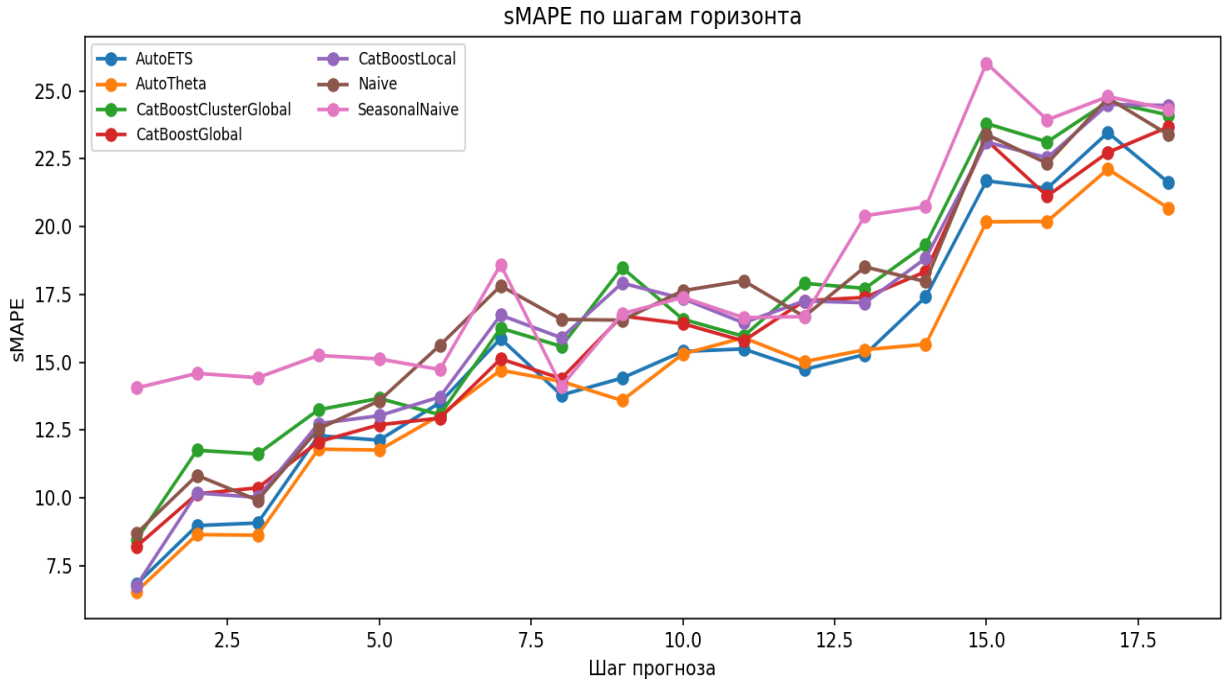
sMAPE по шагам горизонта
AutoETS
AutoTheta
CatBoostClusterGlobal
CatBoostGlobal
CatBoostLocal
Naive
SeasonalNaive
sMAPE
7.5
10.0
12.5
15.0
17.5
20.0
22.5
25.0
2.5
5.0
7.5
10.0
12.5
15.0
17.5
Шаг прогноза

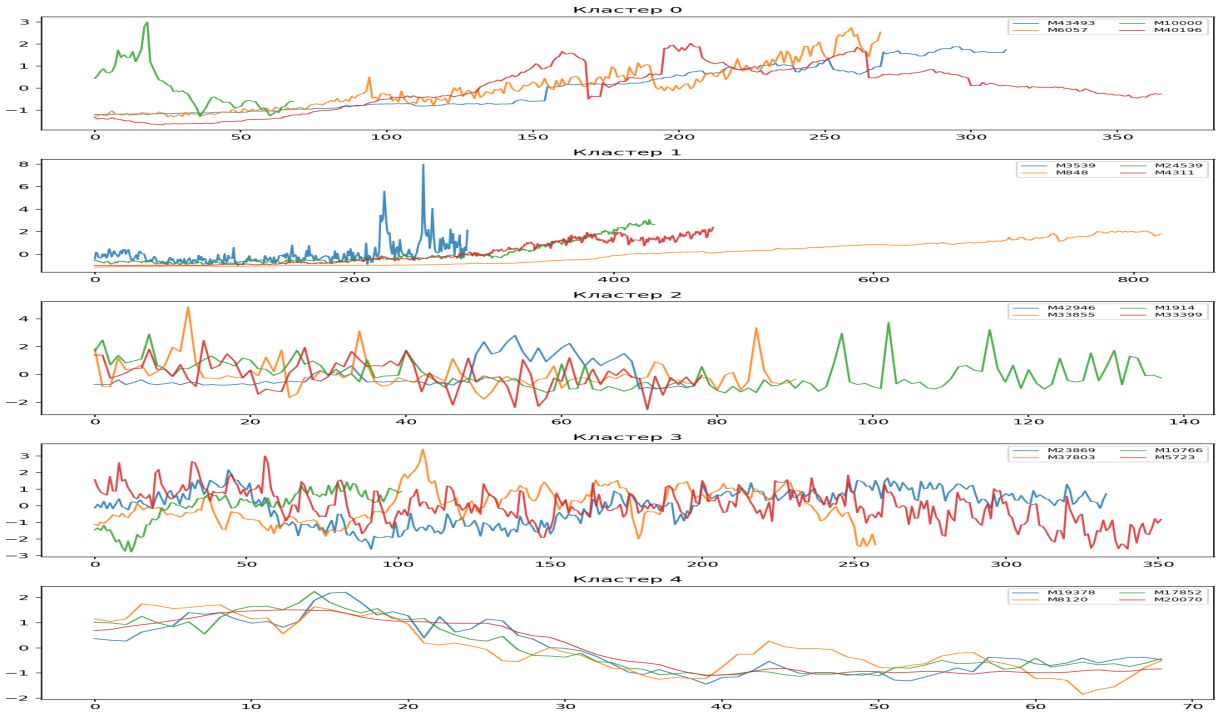

Анализ результатов

Результат по гипотезе получился смешанным. Если сравнивать именно режимы обучения `CatBoost`, то гипотеза частично подтверждается: общий глобальный вариант действительно лучше локального. Значит, объединение информации по нескольким рядам оказалось полезным даже для сравнительно простой табличной модели с лаговыми признаками.

Однако гипотеза не подтвердилась в более сильной формулировке, если включать в сравнение все модели. Лучшие результаты показали не глобальные модели, а классические локальные автоматические подходы `AutoTheta` и `AutoETS`. Это говорит о том, что сама идея глобального обучения полезна не всегда: ее эффективность зависит и от выбранного класса модели, и от того, насколько удачно устроены признаки.

Кластерный вариант `CatBoostClusterGlobal` оказался самым слабым из трех вариантов `CatBoost`. Одна из возможных причин состоит в том, что найденные кластеры были сильно несбалансированными: один кластер включал `64` ряда, два кластера содержали лишь по `4` ряда. В такой ситуации модель внутри маленького кластера уже почти не получает преимуществ глобального обучения, а деление на кластеры может только уменьшать объем доступных данных.

Дополнительный анализ профилей кластеров показывает, что часть кластеров действительно различалась по тренду и сезонности. Например, кластеры `0` и `3` характеризовались высокой автокорреляцией и выраженной сезонной структурой, а кластер `2` имел более слабую автокорреляцию и заметно меньшую силу тренда.

Тем не менее само наличие различий между кластерами не гарантировало улучшения качества прогноза после разбиения выборки.

Выводы

По итогам эксперимента можно сделать три основных вывода.

Во-первых, гипотеза частично подтверждается внутри класса `CatBoost`: глобальная модель на всех рядах оказалась лучше локальной модели на каждом ряде отдельно. Это означает, что перенос информации между рядами действительно может быть полезен.

Во-вторых, кластеризация в текущей постановке не помогла. Глобальная модель по кластерам не только не улучшила качество относительно общей глобальной модели, но и проиграла локальному `CatBoost`. Вероятно, выбранные признаки кластеризации и сильная несбалансированность кластеров сделали это разбиение неудачным именно для задачи прогнозирования.

В-третьих, на выбранной подвыборке и с текущим набором признаков лучшие результаты показали классические локальные методы `AutoTheta` и `AutoETS`. Следовательно, гипотеза не подтверждается в полном виде: глобальное обучение не гарантирует победу над локальными моделями вообще, хотя и может давать выигрыш внутри конкретного класса моделей.

Ограничения и дальнейшая работа

У проведенного эксперимента есть несколько ограничений:

? использовалась только одна подвыборка из `120` рядов;
? основная глобальная модель была только одна и относилась к табличным алгоритмам;
? кластеризация строилась по простым статистическим признакам, а не по более сложным представлениям формы ряда;
? не использовалась валидация по нескольким окнам.

В дальнейшем было бы полезно повторить эксперимент на нескольких разных подвыборках, проверить другой способ кластеризации и сравнить `CatBoost` с более сильной глобальной моделью, например нейросетевой архитектурой для многорядного прогнозирования.